Sistema de Priorización de Brigadas de Salud Extramurales para Comunidades Indígenas y Rurales Dispersas

Fase 1: Formulación y Exploración

Equipo de Investigación

Jorman David Noriega Davila

Julio Cesar Rios Maldonado

Gabriel Omar Venegas González

Información Institucional

Asignatura: Inteligencia Artificial — Grupo 02

Docente: Tonny Jimenez

Institución: Universidad Popular del Cesar

Facultad: Ingenierías y Tecnologías

Programa: Ingeniería de Sistemas e Informática

Lugar y año: Valledupar, Cesar — 2026

PLANTEAMIENTO DEL PROBLEMA

¿Cuál es el problema?

Las comunidades rurales e indígenas de Colombia enfrentan barreras estructurales que impiden el acceso oportuno a servicios de salud. La combinación de factores geográficos, socioeconómicos y de infraestructura crea una brecha crítica en la cobertura sanitaria.

Dispersión Geográfica

Comunidades rurales e indígenas alejadas de centros urbanos, con asentamientos dispersos en territorios de difícil delimitación administrativa.

Deficiencias en Vías de Acceso

Infraestructura vial limitada y difícil transitabilidad que impide el desplazamiento regular de personal de salud hacia estas zonas.

Ausencia de Infraestructura Médica Fija

Falta de centros de salud permanentes en zonas rurales dispersas, dejando a las brigadas extramurales como único punto de contacto con el sistema de salud.

Condiciones Socioeconómicas Críticas

Altos índices de Necesidades Básicas Insatisfechas (NBI) que elevan la carga de enfermedad y la vulnerabilidad sanitaria de estas poblaciones.

⊗ **Consecuencia directa:** Una parte significativa de esta población no recibe atención preventiva ni curativa de manera oportuna, perpetuando ciclos de enfermedad prevenible y exclusión del sistema de salud.

DIAGNÓSTICO ACTUAL

¿Cómo se asignan actualmente las brigadas?

Las Secretarías de Salud e IPS asignan brigadas extramurales utilizando criterios empíricos, presupuestos fijos y solicitudes informales — mecanismos que carecen de sustento técnico y datos objetivos.

1. Inequidad en la Atención

Comunidades con mayor vulnerabilidad pueden quedar desatendidas por falta de visibilidad estadística. La asignación basada en solicitudes informales favorece a territorios con mayor capacidad de gestión administrativa.

2. Uso Ineficiente de Recursos

Desplazamiento de personal a zonas de menor demanda real o duplicidad de esfuerzos entre entidades. Los recursos limitados del sistema de salud se distribuyen sin criterios de maximización de impacto.

3. Falta de Predictibilidad

Dificultad para anticipar picos de demanda relacionados con épocas climáticas o perfiles epidemiológicos locales, impidiendo una planificación proactiva de las brigadas.

1

Criterios Empíricos

Sin respaldo en datos objetivos

2

Presupuestos Fijos

Sin análisis de demanda real

3

Solicitudes Informales

Sin priorización técnica

4

Brecha de Cobertura

Poblaciones vulnerables desatendidas

JUSTIFICACIÓN TÉCNICA

¿Por qué utilizar Inteligencia Artificial?

La Inteligencia Artificial y la Investigación Operativa transforman el proceso de planificación mediante la integración estructurada de múltiples fuentes de datos, permitiendo pasar de decisiones intuitivas a decisiones basadas en evidencia cuantitativa.

Datos Demográficos

Censo DANE — Distribución poblacional georreferenciada

Datos de Afiliación

Régimen subsidiado, contributivo y vinculado

Indicadores Socioeconómicos

CNPV — Miseria, vivienda, hacinamiento y dependencia

Registro Especial de Prestadores y Sedes de Servicios de Salud – REPS

Registros Individuales de Prestación de Servicios de Salud – RIPS

¿Qué propone el sistema?

Scoring de Vulnerabilidad Multicriterio: Índice ponderado que combina variables demográficas, epidemiológicas y socioeconómicas para clasificar cada corregimiento según su necesidad de atención.

Optimización Lineal Entera Mixta (MILP): Modelo matemático que determina la asignación óptima de brigadas bajo restricciones de presupuesto, personal y accesibilidad vial.

Propósito: Lograr una asignación más objetiva y eficiente, maximizando cobertura en zonas de difícil acceso con recursos limitados.

OBJETIVOS DEL PROYECTO

¿Qué queremos lograr?

> **Objetivo General:** Desarrollar un sistema inteligente de priorización y optimización espacial, basado en modelos de scoring, analítica predictiva de demanda y programación lineal, para planificar la asignación de brigadas de salud extramurales en comunidades indígenas y rurales dispersas.

Objetivos Específicos — Ruta de implementación:

1. ## Consolidar y preprocesar fuentes de datos

   Integración de BDUA, Censo DANE y NBI en un repositorio unificado, con procesos de limpieza, normalización y validación de calidad de datos.

2. ## Análisis Exploratorio de Datos georreferenciado (EDA)

   Caracterización espacial de comunidades, identificación de patrones de vulnerabilidad y visualización de la distribución geográfica de la demanda potencial.

3. ## Estimar la demanda proyectada mediante Machine Learning

   Construcción de modelos de regresión supervisada para predecir el volumen de demanda médica por corregimiento, incorporando variables epidemiológicas y estacionales.

4. ## Optimizar rutas y asignación de brigadas (MILP)

   Formulación y resolución del problema de asignación mediante Programación Lineal Entera Mixta, maximizando cobertura y minimizando costos de desplazamiento.

5. ## Construir un prototipo interactivo con mapas

   Desarrollo de un dashboard geoespacial con Folium/QGIS para visualizar los resultados de la optimización y apoyar la toma de decisiones de las Secretarías de Salud.

ARQUITECTURA DEL SISTEMA

Enfoque Híbrido de Inteligencia Artificial

El sistema integra dos componentes complementarios: un módulo predictivo que estima la demanda y cuantifica la vulnerabilidad, y un módulo prescriptivo que optimiza la asignación operativa de brigadas bajo restricciones reales.

Componente Predictivo

Machine Learning + Scoring Multicriterio

- Aprendizaje Supervisado (regresión)
- Scoring ponderado de vulnerabilidad
- Variables: NBI, demografía, epidemiología

¿Qué produce? Predice el volumen estimado de demanda médica y calcula un índice ponderado de vulnerabilidad para cada corregimiento, permitiendo una clasificación objetiva de prioridades.

Componente Prescriptivo

Investigación Operativa + Optimización

- Programación Lineal Entera Mixta (MILP)
- Herramientas: PuLP / OR-Tools (Python)
- Restricciones: presupuesto, personal, acceso vial

¿Qué produce? Determina qué comunidades visitar, con qué frecuencia y con qué personal, maximizando cobertura y minimizando costos de transporte bajo restricciones operativas.

1

Datos

BDUA · DANE · NBI · Cartografía

2

Predicción / Scoring

ML + Índice de vulnerabilidad

3

Optimización

MILP — Asignación óptima

4

Plan de Brigadas

Mapa interactivo de decisiones

METODOLOGÍA

Flujo Propuesto del Sistema

El sistema opera en cinco etapas secuenciales y dependientes. Cada etapa transforma los datos de entrada en un producto analítico que alimenta la siguiente fase, culminando en un instrumento de apoyo a la toma de decisiones.



El flujo garantiza que cada decisión de asignación esté respaldada por evidencia cuantitativa: los datos brutos se transforman progresivamente en un plan operativo de brigadas, con trazabilidad completa desde la fuente hasta el resultado.

Resultado final: Mapa interactivo geoespacial para apoyar la toma de decisiones de las Secretarías de Salud con criterios técnicos objetivos.

ESTADO DEL ARTE

Investigaciones Relacionadas

Tres investigaciones recientes respaldan la viabilidad y pertinencia del enfoque propuesto, demostrando que la combinación de análisis geoespacial, criterios de vulnerabilidad y optimización matemática mejora sustancialmente la planificación de servicios móviles de salud.

Tanim et al. (2026)

Optimizing mobile health clinic placement via geospatial modeling

- Localización y asignación de clínicas móviles mediante modelos geoespaciales
- Maximal Coverage Location Problem (MCLP)
- Herramientas: ArcGIS Pro + Network Analyst
- Resultado: mejoras de cobertura mediante reubicación estratégica de unidades móviles

Roy & Kar (2022)

A multicriteria decision analysis framework to measure equitable healthcare access during COVID-19

- Marco MCDA para análisis de acceso equitativo a servicios de salud
- Análisis de ruta de menor costo integrando factores espaciales
- Incorporación de determinantes socioeconómicos en la priorización

Callaghan, Potgieter & Le Roux (2025)

Mobile clinics routing and scheduling in the Witzenberg region of South Africa

- Optimización de rutas y horarios de clínicas móviles en contextos rurales
- mVRPTW + programación entera + AHP para priorización multicriterio
- Herramientas: Python, VRPSolver y LINGO

Conclusión del estado del arte: Estos trabajos validan el uso combinado de análisis espacial, criterios de vulnerabilidad y optimización matemática como enfoque técnicamente sólido para mejorar la planificación de servicios móviles de salud en contextos de recursos limitados.

ESTADO DEL ARTE

Diagrama de Gantt

FASE · ACTIVIDAD	ENTREGABLE	Sem 1	Sem 2	Sem 3	Sem 4	Sem 5	Sem 6	Sem 7	Sem 8	Sem 9	Sem 10	Sem 11	Sem 12
Fase 1 Def. del problema, Estado del arte, Limpieza de datos (BDUA/DANE/NBI) y EDA	Documento propuesta + Notebook EDA												
Fase 2 Feature Engineering, Creación de matriz distancia/tiempo y Baseline de Scoring	Repositorio GitHub con scripts base												
Fase 2 Entrenamiento del Modelo de ML para predicción de demanda + Modelo de Optimización (PuLP/OR-Tools)	Evaluación cuantitativa y comparación												
Fase 2 Ajuste de hiperparámetros y consolidación técnica	Documento técnico de avance												
Fase 3 Integración del modelo predictivo con la interfaz interactiva (Streamlit / Folium)	Solución integrada												
Fase 3 Despliegue en la nube (Hugging Face / Streamlit Community Cloud)	App Web desplegada												
Fase 3 Evaluación de impacto ético, sesgos de datos y redacción del informe	Informe final borrador												
Fase 3 Grabación del Video Pitch (3-5 min) y Sustentación Final	Video + Repositorio final												

DATOS Y METODOLOGÍA

Fuentes de Datos

¿Con qué datos trabajaremos y cómo los generamos?

El dataset utilizado en este proyecto se construye a partir de datos reales de fuentes oficiales colombianas, integrados mediante un pipeline ETL reproducible. Las fuentes definen tanto el esquema de variables como el origen real de los datos para la planificación en salud.

Fuentes usadas

Fuente	Qué es	Entidad	Acceso	Cobertura
DIVIPOLA	Códigos de municipios	DANE (datos.gov.co)	API SODA v3 gdxc-w37w	vigente
RIPS	Registros Individuales de Prestación de Servicios de Salud	MinSalud	API SODA v3 4k9h-8qiu	2017–2021
REPS	Registro Especial de Prestadores y Sedes	MinSalud	API SODA v3 c36g-9fc2	corte 12-mar-2026
Resguardos 2020	Resguardos indígenas y su población	datos.gov.co	API SODA v3 epzt-64uw	2020
Comunidades 2020	Comunidades indígenas fuera de resguardo	datos.gov.co	API SODA v3 fmd2-kgwe	2020
Proyecciones DANE	Población municipal por área	DANE (PPED)	descarga PPED-AreaMun-2018-2042_VP.xlsx	2018–2042

Fuente de los datos: registros oficiales reales (MinSalud RIPS · DANE DIVIPOLA · MinSalud REPS · Resguardos 2020 · Comunidades 2020 · Proyecciones DANE PPED).
Diagrama de flujo: Fuentes oficiales (API SODA v3 / DANE) → ETL/limpieza → Dataset analítico → Índice de priorización.

DATOS Y METODOLOGÍA

Fuentes de Datos

A. Llave y tiempo

Variable	Descripción
cod_mpio	Código DIVIPOLA del municipio (llave)
cod_dpto	Código DIVIPOLA del departamento
nom_mpio	Nombre del municipio
a_o	Año (2017–2021)
banda_pob	Quintil de población (0 = más pequeño, 4 = más grande)

B. Demanda RIPS

Variable	Descripción
consultas	Atenciones tipo CONSULTAS
procedimientos	Atenciones tipo PROCEDIMIENTOS DE SALUD
urgencias	Atenciones tipo URGENCIAS
hospitalizaciones	Atenciones tipo HOSPITALIZACIONES
atenciones_total	Suma de los 4 tipos de atención
sin_rips	Indica si el municipio-año no tiene registros RIPS

Fuente de los datos: registros oficiales reales (MinSalud RIPS · DANE DIVIPOLA · MinSalud REPS · Resguardos 2020 · Comunidades 2020 · Proyecciones DANE PPED).
Diagrama de flujo: Fuentes oficiales (API SODA v3 / DANE) → ETL/limpieza → Dataset analítico → Índice de priorización.

DATOS Y METODOLOGÍA

Fuentes de Datos

C. Perfil diagnóstico CIE-10

¿Qué responde?

B. Demanda: ¿Cuánto se atendió? → volumen de servicios.
C. Perfil CIE-10: ¿De qué se atendió? → mezcla de diagnósticos.

¿Qué representa?

Cada pct_cap_X indica el porcentaje de atenciones pertenecientes a un capítulo CIE-10:

pct_cap_X = atenciones del capítulo X ÷ total de atenciones × 100

- **Fuente: RIPS, código de diagnóstico CIE-10.**
- **La primera letra del código identifica el capítulo.**
- **Denominador: consultas + urgencias + hospitalizaciones.**
- **Perfil calculado con RIPS 2017–2021.**
- **Las 26 categorías A–Z forman la composición diagnóstica del municipio.**

¿Cómo se interpreta?

Municipio	Perfil CIE-10 predominante	Interpretación
Medellín	**Z 19% · R 13% · K 9% · M 9% · I 7% · J 6%**	Predominan factores relacionados con **controles/seguimiento, síntomas y enfermedades crónicas**.
Roberto Payán	**Z 24% · R 23% · A 13% · B 11%**	Mayor peso relativo de capítulos **infecciosos y parasitarios**.
Puerto Arica / Cacahual	**0 / 26 capítulos**	**Sin registros RIPS**; perfil diagnóstico nulo.

DATOS Y METODOLOGÍA

Fuentes de Datos

C. Perfil diagnóstico CIE-10

pct_cap_X = atenciones con diagnóstico del capítulo X ÷ total de atenciones del municipio × 100

Variable	Descripción
pct_cap_A	% de atenciones del capítulo CIE-10 A — Enfermedades infecciosas y parasitarias
pct_cap_B	% de atenciones del capítulo CIE-10 B
pct_cap_C	% de atenciones del capítulo CIE-10 C
pct_cap_D	% de atenciones del capítulo CIE-10 D
pct_cap_E	% de atenciones del capítulo CIE-10 E
pct_cap_F	% de atenciones del capítulo CIE-10 F
pct_cap_G	% de atenciones del capítulo CIE-10 G
pct_cap_H	% de atenciones del capítulo CIE-10 H
pct_cap_I	% de atenciones del capítulo CIE-10 I
pct_cap_J	% de atenciones del capítulo CIE-10 J — Enfermedades respiratorias
pct_cap_K	% de atenciones del capítulo CIE-10 K — Enfermedades digestivas
pct_cap_L	% de atenciones del capítulo CIE-10 L
pct_cap_M	% de atenciones del capítulo CIE-10 M
pct_cap_N	% de atenciones del capítulo CIE-10 N
pct_cap_O	% de atenciones del capítulo CIE-10 O — Embarazo, parto y puerperio
pct_cap_P	% de atenciones del capítulo CIE-10 P
pct_cap_Q	% de atenciones del capítulo CIE-10 Q
pct_cap_R	% de atenciones del capítulo CIE-10 R
pct_cap_S	% de atenciones del capítulo CIE-10 S
pct_cap_T	% de atenciones del capítulo CIE-10 T
pct_cap_U	% de atenciones del capítulo CIE-10 U
pct_cap_V	% de atenciones del capítulo CIE-10 V
pct_cap_W	% de atenciones del capítulo CIE-10 W
pct_cap_X	% de atenciones del capítulo CIE-10 X
pct_cap_Y	% de atenciones del capítulo CIE-10 Y
pct_cap_Z	% de atenciones del capítulo CIE-10 Z

DATOS Y METODOLOGÍA

Fuentes de Datos

D. Infraestructura REPS

Variable	Descripción
n_sedes	Número de sedes de salud habilitadas en el municipio
n_sedes_ese	Número de sedes públicas pertenecientes a una E.S.E.

E. Contexto étnico

Variable	Descripción
n_resguardos	Número de resguardos indígenas
pob_resguardos	Población ubicada en resguardos indígenas
n_comunidades	Número de comunidades indígenas fuera de resguardo

F. Población y ruralidad — DANE

Variable	Descripción
poblacion	Población proyectada utilizada como denominador
pct_rural_disperso	Porcentaje de población en Centros Poblados y Rural Disperso

DATOS Y METODOLOGÍA

Fuentes de Datos

G. Indicadores derivados

Variable	Descripción
consultas_1000hab	Tasa de consultas por cada 1.000 habitantes
urgencias_1000hab	Tasa de urgencias por cada 1.000 habitantes
hosp_1000hab	Tasa de hospitalizaciones por cada 1.000 habitantes
proced_1000hab	Tasa de procedimientos por cada 1.000 habitantes
ratio_consultas_urgencias	Relación entre consultas y urgencias
sedes_10k_hab	Número de sedes de salud por cada 10.000 habitantes

H. Variables objetivo — Target

Variable	Descripción
bench_consultas	Benchmark: mediana de la tasa de consultas de su banda de
bench_global	Benchmark: mediana de la tasa de atenciones totales de su
brecha_consultas	Brecha respecto al benchmark de consultas. 0 = nivel de sus
brecha_global	Brecha respecto al benchmark de atenciones totales
brecha_nacional	Versión legacy basada en benchmark nacional
es_hub	1 = prestador que sirve un área de influencia; se excluye del
prioridad_alta	1 = prioridad alta cuando la brecha está en el tercio superior y no

SÍNTESIS · FASE 1

De los Datos a una Decisión Inteligente

Cadena de Valor del Sistema

Datos reales → Análisis de vulnerabilidad → Predicción de demanda → Optimización de recursos → Priorización de comunidades → **Planificación de brigadas de salud**

Cada eslabón de la cadena transforma información bruta en conocimiento accionable, garantizando que las decisiones de asignación de brigadas sean técnicamente fundamentadas, reproducibles y auditables.

Lo que establece esta Fase 1

- **Definición clara del problema** — Caracterización de la brecha de cobertura en comunidades rurales e indígenas dispersas
- **Justificación de pertinencia** — Limitaciones del modelo empírico actual y ventajas del enfoque basado en datos
- **Objetivos específicos y medibles** — Cinco hitos técnicos con entregables definidos
- **Enfoque híbrido de IA** — Componente predictivo (ML + Scoring) articulado con componente prescriptivo (MILP)
- **Estado del arte validado** — Tres trabajos de referencia internacional en contextos similares
- **Fuentes de datos identificadas** — BDUA, DANE, NBI, IGAC y OpenStreetMap como insumos oficiales

> **Propósito de la Fase 1:** Convertir datos de vulnerabilidad, demanda y territorio en decisiones para una mejor planificación de las brigadas de salud — sentando las bases metodológicas y técnicas del proyecto completo.

Gracias — Universidad Popular del Cesar · Inteligencia Artificial · Grupo 02 · 2026