UNIVERSIDAD POPULAR DEL CESAR

FACULTAD DE INGENIERÍAS Y TECNOLOGÍAS

PROGRAMA DE INGENIERÍA DE SISTEMAS

SISTEMA DE PRIORIZACIÓN DE BRIGADAS DE SALUD EXTRAMURALES PARA COMUNIDADES INDÍGENAS Y RURALES DISPERSAS

Documento Técnico de Avance – Segunda Fase (Segundo Corte)

PRESENTADO POR:

JORMAN DAVID NORIEGA DÁVILA
JULIO CESAR RIOS MALDONADO
GABRIEL OMAR VENEGAS GONZÁLEZ

ASIGNATURA:
INTELIGENCIA ARTIFICIAL

GRUPO:
02

DOCENTE:
TONNY JIMENEZ

VALLEDUPAR, CESAR
2026

Índice

1. Introducción **2**

2. Estado del Arte **2**
2.1. Internacional 2
2.2. Nacional 2
2.3. Local 3

3. Planteamiento del Problema **3**

4. Objetivos **3**
4.1. Objetivo General 3
4.2. Objetivos Específicos 3

5. Justificación **4**

6. Metodología **4**
6.1. Tipo y Enfoque de Investigación 4
6.2. Método de la Investigación 5
6.3. Fases del Proyecto de Aula 5
6.4. Actividades a Desarrollar por Cada Objetivo Específico 5
6.5. Partición de Datos 70 / 15 / 15 Agrupada 6

7. Desarrollo, Modelado y Evaluación Cuantitativa (Fase 2) **6**
7.1. Evaluación Comparativa de Modelos de Machine Learning 6
7.2. Ajuste de Hiperparámetros 7
7.3. Curvas ROC y Matrices de Confusión 7
7.4. Importancia de Variables y Explicabilidad 8
7.5. Componente Prescriptivo: Optimización MILP y Asignación Geodésica . . . 10
7.5.1. Demostración Operativa en el Departamento del Cesar 10

Referencias Bibliográficas **11**

1. Introducción

El acceso equitativo a servicios de salud de atención primaria representa uno de los desafíos más complejos de salud pública en Colombia. En las regiones rurales apartadas y en los territorios colectivos indígenas, la distancia física a los centros urbanos y la precaria infraestructura vial imponen barreras casi insalvables para los pacientes. Como consecuencia, las brigadas médicas extramurales constituyen con frecuencia el único mecanismo de contacto preventivo y curativo con el sistema sanitario institucional.

No obstante, la planeación y el despliegue de estos operativos móviles suelen basarse en criterios empíricos, presiones presupuestales coyunturales o solicitudes informales, lo que ocasiona duplicidad de esfuerzos en ciertas zonas y desatención prolongada en comunidades en extrema vulnerabilidad. El presente documento reporta la consolidación técnica y metodológica de la **Segunda Fase (Desarrollo y Modelado)** de un sistema inteligente de priorización y optimización espacial. Mediante la integración de datos abiertos oficiales (RIPS, REPS, Censo DANE 2018 NBI y cartografía DIVIPOLA), se desarrollaron y contrastaron modelos de aprendizaje automático supervisado y un componente prescriptivo de Programación Lineal Entera Mixta (MILP) para transformar la toma de decisiones asistenciales en una política basada en evidencia cuantitativa.

2. Estado del Arte

2.1. Internacional

La optimización espacial de clínicas móviles de salud ha cobrado relevancia en la literatura científica reciente. Tanim et al. (2026) desarrollaron un marco de localización-asignación tipo *Maximal Coverage Location Problem* (MCLP) para el despliegue de clínicas móviles en entornos rurales, demostrando un incremento del 90 % en la cobertura poblacional mediante la relocalización sistemática basada en tiempos de viaje. Por su parte, Callaghan et al. (2025) abordaron la planificación de clínicas móviles en la región de Witzenberg (Sudáfrica) implementando un modelo jerárquico de enrutamiento de vehículos con ventanas de tiempo (m-VRPTW) y programación entera para balancear la fatiga del personal médico y minimizar las distancias recorridas.

2.2. Nacional

En el contexto latinoamericano y colombiano, Roy y Kar (2022) introdujeron un marco de análisis de decisión multicriterio (MCDA) combinado con análisis de rutas de menor costo para cuantificar las barreras socioeconómicas y geográficas en el acceso a servicios de salud. En Colombia, el uso secundario de las bases de datos masivas del Sistema General de Seguridad Social en Salud (SGSSS), como el Registro de Prestadores (REPS) y los Registros

Individuales de Prestación de Servicios (RIPS), ha sido propuesto como insumo estratégico para caracterizar la brecha territorial en zonas ZOMAC y municipios PDET [5].

2.3. Local

En el departamento del Cesar y la región de la Sierra Nevada de Santa Marta y la Serranía del Perijá, la dispersión de comunidades indígenas (pueblos Arhuaco, Wiwa, Kankuamo y Yukpa) plantea retos logísticos severos. La ausencia de vías pavimentadas y la dependencia de transporte fluvial o trochas de herradura demandan herramientas computacionales que optimicen las rutas de salida desde las cabeceras municipales y hospitales de referencia regional como el Hospital Rosario Pumarejo de López en Valledupar. Para cuantificar estas barreras se adopta el enfoque multicriterio y de rutas de menor costo propuesto por Roy y Kar [3].

3. Planteamiento del Problema

La asignación tradicional de brigadas de salud extramurales en Colombia adolece de tres fallas estructurales:

a) **Inequidad en la cobertura asistencial:** Asentamientos con Necesidades Básicas Insatisfechas (NBI) críticas no reciben visitas oportunas debido a su invisibilidad estadística en las secretarías de salud.

b) **Ineficiencia operativa y de costos:** Desplazamiento de vehículos y equipos multidisciplinarios a zonas con menor urgencia relativa, elevando los costos de combustible, desgaste vehicular y viáticos sin maximizar el impacto sanitario.

c) **Falta de predictibilidad epidemiológica:** Incapacidad de anticipar el déficit crónico en la atención primaria ambulatoria según perfiles sociodemográficos y geográficos.

4. Objetivos

4.1. Objetivo General

Desarrollar un sistema inteligente de priorización y optimización espacial, basado en modelos de *scoring*, analítica predictiva de demanda y programación lineal, para planificar la asignación de brigadas de salud extramurales en comunidades indígenas y rurales dispersas.

4.2. Objetivos Específicos

1. Consolidar y preprocesar las bases de datos oficiales de demanda médica (RIPS), infraestructura (REPS), contexto étnico (MinInterior) e indicadores de Necesidades Básicas Insatisfechas (DANE) a nivel municipal.

2. Desarrollar un análisis exploratorio de datos (EDA) georreferenciado para identificar patrones de vulnerabilidad, dispersión sanitaria y puntos de referencia hospitalaria (*hubs*).

3. Formular, calibrar y evaluar modelos de *Machine Learning* supervisado para estimar la probabilidad de déficit asistencial y priorización de brigadas.

4. Diseñar e implementar un modelo de optimización prescriptiva (Programación Lineal Entera Mixta - MILP) que determine el despacho óptimo de brigadas bajo restricciones logísticas y de equidad territorial.

5. Construir un prototipo interactivo con soporte de mapas para apoyar la toma de decisiones operativas de las Secretarías de Salud.

5. Justificación

La integración de la Inteligencia Artificial Predictiva (*Machine Learning*) con la Investigación de Operaciones Prescriptiva permite transitar de un esquema reactivo y discrecional a un esquema proactivo y sustentado en evidencia. Al modelar la vulnerabilidad multidimensional no solo a partir del volumen total de habitantes, sino incorporando el NBI específico de la zona rural dispersa y las coordenadas geográficas de los municipios, el sistema permite una distribución más objetiva, verificable y auditable de los recursos públicos de salud.

Asimismo, desde el punto de vista logístico, planificar los despachos desde bases operativas consolidadas minimiza tiempos de traslado y previene el aislamiento prolongado de comunidades con alta densidad de resguardos indígenas.

6. Metodología

6.1. Tipo y Enfoque de Investigación

La investigación es de carácter **aplicado, cuantitativo y correlacional-explicativo**:

- **Aplicada:** Plantea una solución directa y computable a un problema operativo del sector salud en Colombia.
- **Cuantitativa:** Utiliza indicadores empíricos oficiales, registros masivos de atenciones médicas, censos demográficos y formulaciones matemáticas.
- **Correlacional:** Analiza la asociación entre la infraestructura fija instalada, el grado de dispersión territorial, la pobreza multidimensional y el desabastecimiento de atención primaria, sin pretender establecer relaciones de causalidad.

6.2. Método de la Investigación

Se adoptó la metodología estándar **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), adaptada específicamente para analítica en salud pública y optimización logística:

1. **Comprensión del Negocio/Dominio:** Caracterización de los lineamientos del Ministerio de Salud para equipos extramurales y formulación del benchmark de brecha asistencial relativa por quintiles de población.

2. **Comprensión y Extracción de Datos:** Integración de 6 fuentes de datos abiertos oficiales del Estado Colombiano (SODA v3 y DANE).

3. **Preparación de Datos:** Depuración de coordenadas GPS decimales, imputación de medianas para causas CIE-10 atípicas y estructuración del panel analítico (5.610 filas $\times$ 74 columnas).

4. **Modelado Predictivo y Prescriptivo:** Entrenamiento de algoritmos de clasificación supervisada y formulación del modelo MILP.

5. **Evaluación:** Validación cruzada sobre el conjunto de entrenamiento (partición aleatoria de 3 pliegues, no agrupada por municipio) y evaluación final en un conjunto de prueba ciego (*Test Set*) agrupado por municipio, de modo que ningún territorio evaluado fue observado durante el ajuste.

6. **Despliegue (Fase 3):** Empaquetamiento de los modelos en una aplicación web interactiva con mapas satelitales.

6.3. Fases del Proyecto de Aula

El proyecto se estructuró en tres etapas cronológicas: la **Fase I** consolidó la extracción ETL, la limpieza de centroides geográficos y el panel municipal 2017–2021; la **Fase II**, objeto de este documento, abordó la partición agrupada, el ajuste de hiperparámetros, la evaluación comparativa de clasificadores y la resolución del MILP; la **Fase III** comprenderá el prototipado, la interfaz cartográfica y el despliegue del sistema.

6.4. Actividades a Desarrollar por Cada Objetivo Específico

La Tabla 1 detalla el plan metodológico ejecutado y proyectado para garantizar el cumplimiento de cada uno de los objetivos específicos formulados.

Tabla 1: Matriz de relación entre Objetivos Específicos, Actividades Técnicas y Entregables.

Objetivo Específico	Actividades Técnicas Desarrolladas / Proyectadas	Entregables / Artefactos
Obj. 1: Consolidación y ETL	Consumo automatizado de APIs SODA v3 (DIVIPOLA, RIPS, REPS, Resguardos); ingesta y normalización de microdatos DANE (Censo 2018 NBI rural y proyecciones PPED); corrección y validación de centroides geográficos; consolidación del panel municipal 2017–2021 (5.610 observaciones).	Scripts `etl_00.py` a `etl_06.py`; `build_tabla_modelo.py`; dataset `municipio_anio.parquet` (74 variables).
Obj. 2: EDA Georreferenciado	Estadísticas descriptivas, distribuciones y valores nulos; segmentación municipal en quintiles poblacionales (`banda_pob`); tasa de consultas por 1.000 habitantes y brecha relativa; detección y aislamiento de centros de referencia hospitalaria (*hubs*).	Notebook `eda_dataset.ipynb`; script de reporte `eda.py`; trazabilidad en `eda.log`.
Obj. 3: Modelado Predictivo ML	Selección de 27 variables predictoras sin fuga de información; partición agrupada 70/15/15 por `cod_mpio`; entrenamiento comparativo de cuatro modelos (Dummy, Logística, Random Forest, HistGradientBoosting); calibración con *GridSearchCV* de 3 pliegues; evaluación en test ciego con F1, ROC-AUC y matrices de confusión.	Script `modelado.py`; modelos serializados (`.joblib`); curvas ROC y matrices de confusión; `metricas_comparacion.json`.
Obj. 4: Optimización Prescriptiva	Formulación matemática del MILP; cálculo de distancias geodésicas ortodrómicas por Haversine; restricciones de capacidad de flota y cuota indígena obligatoria; resolución con el solver HiGHS y validación piloto en el departamento del Cesar.	Script `optimizacion_milp.py`; plan de despacho (`asignacion_brigadas_optima.csv`).

6.5. Partición de Datos 70 / 15 / 15 Agrupada

Para prevenir la autocorrelación intra-municipal entre años consecutivos (evitando el *Data Leakage* o fuga de información temporal), la división se ejecutó sobre los códigos únicos municipales (`cod_mpio`):

- **Train (70 %):** 785 municipios completos → 3.925 registros panel (3.770 válidos tras aislar *hubs*).
- **Validation (15 %):** 168 municipios completos → 840 registros panel (807 válidos).
- **Test Ciego (15 %):** 169 municipios completos → 845 registros panel (817 válidos).

7. Desarrollo, Modelado y Evaluación Cuantitativa (Fase 2)

7.1. Evaluación Comparativa de Modelos de Machine Learning

Se evaluaron cuatro enfoques algorítmicos en el conjunto de prueba ciego (*Test Set*), garantizando que el modelo evaluara territorios que jamás observó durante la etapa de entrenamiento. Los resultados cuantitativos se exponen en la Tabla 2.

Tabla 2: Evaluación comparativa de modelos en el conjunto de prueba ciego (Test Set).

Modelo Evaluado	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
HistGradientBoosting	**0.7797**	**0.7413**	0.5379	**0.6234**	**0.7848**	**0.7414**
Random Forest (Optimizado)	0.7283	0.6211	0.5090	0.5595	0.7653	0.6803
Regresión Logística	0.6573	0.4952	**0.5596**	0.5254	0.6920	0.5926
Dummy Baseline (Trivial)	0.6610	0.0000	0.0000	0.0000	0.5000	0.3390

El algoritmo **HistGradientBoosting** superó holgadamente a los demás enfoques con un **F1-Score de 0.6234**, un **ROC-AUC de 0.7848** y un área bajo la curva Precision-Recall (PR-AUC) de 0.7414. Resulta de especial relevancia su precisión de **74.13 %**: en un contexto de recursos públicos limitados, esto implica que aproximadamente 3 de cada 4 registros municipio–año clasificados como prioritarios corresponden efectivamente a un déficit asistencial, lo que reduce el riesgo de asignar brigadas a territorios no prioritarios.

7.2. Ajuste de Hiperparámetros

El proceso experimental se documenta en la Tabla 3. La Regresión Logística se empleó como línea base lineal con ponderación de clases balanceada y sin búsqueda de hiperparámetros; el Random Forest y el HistGradientBoosting se optimizaron mediante *GridSearchCV* con validación cruzada de tres pliegues y criterio de selección F1-Score, evaluando respectivamente 12 y 24 combinaciones.

Tabla 3: Espacio de búsqueda y mejores hiperparámetros seleccionados (GridSearchCV, 3 pliegues, criterio F1).

Modelo	Malla evaluada	Mejor configuración
Random Forest	`n_estimators` $\in \{100, 200\}$; `max_depth` $\in \{6, 10, \text{sin límite}\}$; `min_samples_split` $\in \{2, 5\}$; `class_weight` = *balanced*	200 árboles; profundidad 6; `min_samples_split` = 2; pesos balanceados
HistGradientBoosting	`learning_rate` $\in \{0{,}03, 0{,}08, 0{,}15\}$; `max_iter` $\in \{100, 150\}$; `max_leaf_nodes` $\in \{15, 31\}$; `min_samples_leaf` $\in \{20, 40\}$	Tasa 0,15; 100 iteraciones; 15 hojas; 20 muestras mínimas por hoja

7.3. Curvas ROC y Matrices de Confusión

En la Figura 1 se presenta la comparación de las Curvas Características Operativas del Receptor (ROC). El clasificador HistGradientBoosting mantiene una clara dominancia estocástica a lo largo de todo el espectro de corte.

La Figura 2 presenta las matrices de confusión de los tres modelos funcionales sobre las 817 observaciones de prueba. El HistGradientBoosting clasifica correctamente 488 registros no prioritarios y 149 prioritarios, con 52 falsos positivos y 128 falsos negativos. Su precisión

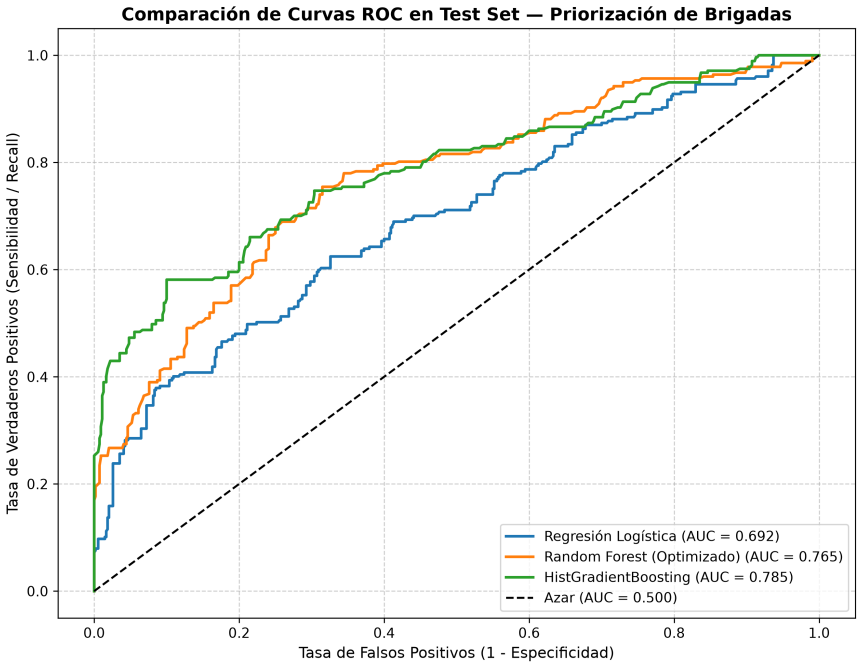


Figura 1: Curvas ROC comparativas en el conjunto de prueba ciego (Test Set).

(74.13 %) indica que tres de cada cuatro alertas son correctas, mientras que el recall (53.79 %) evidencia que cerca del 46 % de los registros realmente prioritarios no se detectan con el umbral de 0.5. El comportamiento es conservador en el uso de recursos y debe compensarse con revisión humana o con un umbral de decisión ajustable; el conjunto de validación queda disponible para calibrar dicho umbral en la siguiente iteración.

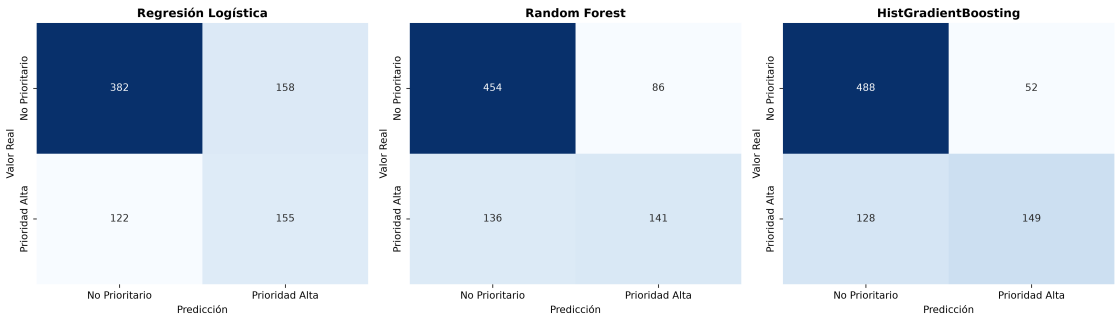


Figura 2: Matrices de confusión comparativas sobre el conjunto de prueba ciego.

7.4. Importancia de Variables y Explicabilidad

La Figura 3 presenta la importancia Gini del Random Forest optimizado. En el ranking individual dominan el perfil de diagnósticos y la vulnerabilidad étnica y social:

1. **Capítulo CIE-10 O (embarazo, parto y puerperio):** 0.112. Es la variable con mayor reducción de impureza y refleja el peso de la demanda obstétrica en el perfil municipal.

2. **Población en resguardos:** 0.091. Concentración de población indígena sujeta a barreras geográficas de acceso.

3. **NBI servicios:** 0.085. Carencias en servicios básicos y saneamiento.

4. **NBI rural servicios:** 0.059. Las mismas carencias en centros poblados y rural disperso.

5. **Capítulo CIE-10 A (infecciosas y parasitarias):** 0.049. Carga de enfermedad infecciosa asociada a determinantes sociales.

Agregadas por bloque, las once variables de NBI concentran aproximadamente el 42 % de la importancia total, frente al 26 % de los capítulos CIE-10, el 12 % de las variables étnicas, el 15 % de geografía y demografía y el 5 % de la capacidad instalada registrada en REPS. La lectura correcta es que el modelo combina demanda materna e infecciosa con vulnerabilidad social y étnica: la ruralidad dispersa (`pct_rural_disperso`) ocupa el puesto 13 y las sedes por cada 10.000 habitantes el puesto 21, de modo que su efecto es conjunto y no individual. La importancia Gini mide reducción de impureza dentro del ensamble y **no implica causalidad**; el modelo empleado para el despacho es el HistGradientBoosting.

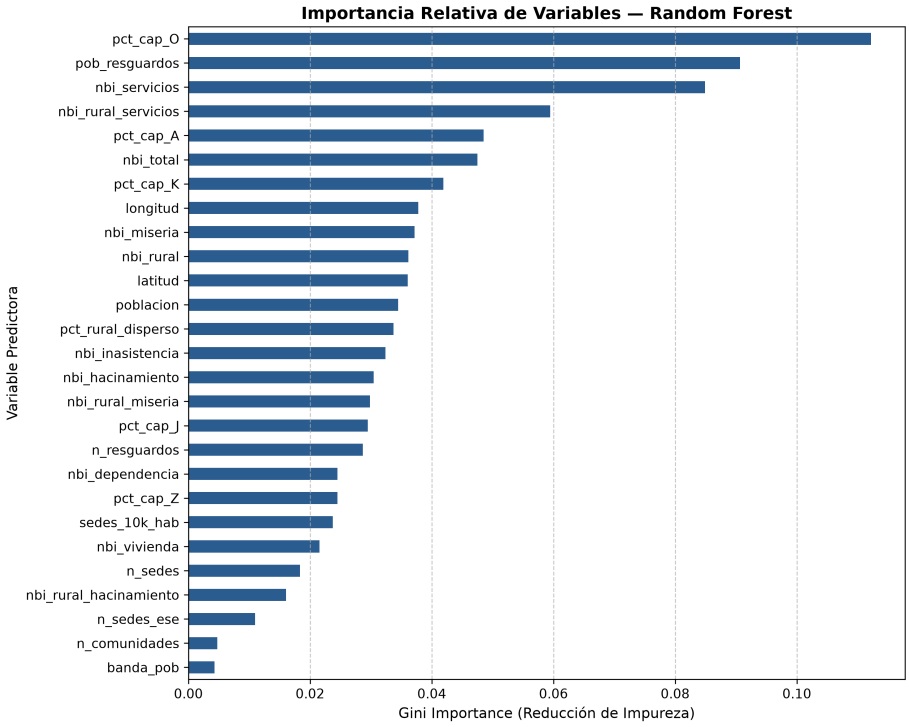


Figura 3: Importancia de variables predictoras en el modelo de ensamble.

7.5. Componente Prescriptivo: Optimización MILP y Asignación Geodésica

Para traducir la predicción estadística en acción logística, se implementó un modelo de Programación Lineal Entera Mixta (MILP) resuelto mediante el solver **HiGHS**:

$$\begin{aligned} \max_{x} \quad & \sum_{i=1}^{N} \Big[P_i \cdot \ln(V_i + 1) - \lambda \cdot d_i \Big] \, x_i \\ \text{s.a.} \quad & \sum_{i=1}^{N} x_i \leq K \qquad \text{(flota móvil disponible)} \\ & \sum_{i \in \mathcal{R}} x_i \geq M \qquad \text{(cuota de cobertura en resguardos)} \\ & d_i \, x_i \leq D_{\text{máx}} \qquad \text{(autonomía máxima de traslado)} \\ & x_i \in \{0, 1\} \quad \forall i \in \{1, \ldots, N\} \end{aligned} \tag{1}$$

donde P_i es la probabilidad de prioridad alta arrojada por el modelo, V_i es la población vulnerable (rural dispersa más población en resguardos), d_i es la distancia geodésica ortodrómica calculada mediante la fórmula de Haversine desde el hospital base, K es el número de brigadas disponibles, M la cuota mínima de municipios con resguardos, $D_{\text{máx}}$ la autonomía operacional y $\lambda = 0{,}005$ la tasa de penalización logística por kilómetro. Para el ejercicio piloto se adoptaron $K = 4$, $M = 2$ y $D_{\text{máx}} = 350$ km.

7.5.1. Demostración Operativa en el Departamento del Cesar

Tomando como base central de despacho el **Hospital Rosario Pumarejo de López en Valledupar** ($10{,}4605°\text{N}, -73{,}2594°\text{W}$) y una dotación de $K = 4$ unidades médicas móviles, el modelo resolvió la asignación óptima expuesta en la Tabla 4.

Tabla 4: Plan de despacho óptimo resuelto para el departamento del Cesar ($K = 4$, $M = 2$).

Municipio	P_i	Pob. vuln.	Dist. base	NBI rural	Brigada
Pueblo Bello	0.369	29.861 hab	36.1 km	86.6 %	**Brigada Móvil #1**
Becerril	0.458	8.160 hab	84.1 km	67.2 %	**Brigada Móvil #2**
Astrea	**0.909**	10.298 hab	132.7 km	37.5 %	**Brigada Móvil #3**
Chimichagua	**0.750**	22.329 hab	146.8 km	30.0 %	**Brigada Móvil #4**

El modelo satisfizo con exactitud la cuota ética y constitucional cubriendo dos zonas con resguardos en la Sierra Nevada y la Serranía del Perijá (Pueblo Bello y Becerril), asignando las dos brigadas restantes a los municipios con mayor probabilidad predictiva de abandono hospitalario (Astrea y Chimichagua).

El modelo entrenado se expone además mediante el script `probar_ia.py`, una interfaz de consola que recupera el vector de las 27 variables de cualquier municipio, aplica el clasificador y reporta la probabilidad de prioridad junto con un diagnóstico descriptivo. Este componente

constituye la demostración funcional del sistema y permite verificar el comportamiento del modelo sin replicar el entorno de entrenamiento.

Referencias Bibliográficas

[1] S. H. Tanim, D. L. White, B. Witrick, and L. Rennert, "Optimizing mobile health clinic placement via geospatial modeling," *Public Health in Practice*, vol. 9, p. 100482, 2026.

[2] H. J. Callaghan, L. Potgieter, and N. Le Roux, "Mobile clinics routing and scheduling in the Witzenberg region of South Africa," *PLOS ONE*, vol. 20, no. 3, p. e0284591, 2025.

[3] A. Roy and B. Kar, "A multicriteria decision analysis framework to measure equitable healthcare access during COVID-19," *Journal of Transport & Health*, vol. 26, p. 101416, 2022.

[4] DANE, "Censo Nacional de Población y Vivienda (CNPV) 2018: Necesidades Básicas Insatisfechas (NBI) a nivel municipal," Departamento Administrativo Nacional de Estadística, Bogotá, 2019.

[5] Ministerio de Salud y Protección Social, "Registro Especial de Prestadores de Servicios de Salud (REPS) y Sistema RIPS," Portal de Datos Abiertos de Colombia, 2021.

[6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[7] Q. Huangfu and J. A. J. Hall, "Parallelizing the dual revised simplex method," *Mathematical Programming Computation*, vol. 10, no. 1, pp. 119–142, 2018.